

UNIVERSIDADE FEDERAL DE SÃO CARLOS

Centro de Ciências Exatas e de Tecnologia

ARQUITETURAS DE ALTO DESEMPENHO

Relatório da Prática 5: Programação em GPU (MATLAB para Python)

Docente: Prof. Dr. Emerson Carlos Pedrino

Discentes

Enzo Dezem Alves

RA: 801743

Curso: Engenharia de Computação

Gustavo de Oliveira Gimenes

RA: 820759

Curso: Engenharia de Computação

Guilherme Bartoletti Oliveira

RA: 821881

Curso: Engenharia de Computação

Gustavo Cesar Bento Laurindo

RA: 821402

Curso: Engenharia de Computação

São Carlos, 4 de julho de 2026

1 Introdução

Tradicionalmente, a computação baseia-se na arquitetura clássica de von Neumann, na qual o processador (CPU) executa instruções sequencialmente sobre um caminho de dados. Embora as CPUs modernas sejam extremamente rápidas e otimizadas para tarefas de baixa latência através de algoritmos complexos de previsão de desvio e memórias cache profundas, elas possuem limitações físicas intransponíveis quando submetidas a cargas de trabalho que exigem processamento paralelo massivo. O processamento sequencial de grandes matrizes ou fluxos de dados multidimensionais esbarra no conhecido "gargalo de barramento de memória" (*memory wall*).

Como alternativa para computação científica de alto desempenho (HPC), consolidou-se o uso de aceleradores baseados em Unidades de Processamento Gráfico (GPUs). Ao contrário das CPUs, que utilizam poucos núcleos otimizados para tarefas sequenciais rápidas, as GPUs utilizam milhares de núcleos mais simples projetados para processamento paralelo massivo guiados pelo paradigma SIMT (*Single Instruction, Multiple Threads*).

Historicamente, o ambiente MATLAB foi muito utilizado para demonstrar o ganho dessas tecnologias através de comandos de abstração de GPU como `gpuArray` e `arrayfun`. No entanto, a indústria e a academia têm migrado massivamente para a linguagem **Python** devido à sua robustez, gratuidade e ao seu poderoso ecossistema de bibliotecas como **NumPy** (CPU vetorizada), **PyTorch** (computação em GPU e Deep Learning) e **Numba** (compilação JIT para kernels CUDA).

Este relatório documenta o desenvolvimento, a adaptação e a análise experimental de duas tarefas computacionais complexas: a Transformada Rápida de Fourier (FFT) tridimensional e o cálculo do Fractal do Conjunto de Mandelbrot. Os códigos originais propostos em MATLAB foram traduzidos e otimizados para Python e validados em uma GPU real de última geração, a **NVIDIA GeForce RTX 3060 Laptop GPU** (arquitetura Ampere, Compute Capability 8.6).

2 Fundamentação Teórica

2.1 Arquitetura CPU vs GPU: O Paradigma SIMT

As CPUs são projetadas para minimizar a latência de execução de uma única thread, dedicando grande parte de sua área de silício a unidades de controle complexas, caches locais massivas e pipelines profundos com execução fora de ordem.

Por outro lado, as GPUs sacrificam o controle complexo e o tamanho do cache para maximizar a vazão de dados (*throughput*). Elas são formadas por múltiplos processadores de streaming (SMs), cada um contendo dezenas de núcleos de processamento aritmético (núcleos CUDA). No modelo SIMT, grupos de threads (chamados de *Warps* de 32 threads)

executam a mesma instrução simultaneamente em diferentes elementos de dados, tornando o processamento de imagens e matrizes extremamente eficiente.

2.2 Gargalo de Barramento PCIe (PCIe Bandwidth Bottleneck)

Um dos conceitos mais importantes e críticos na programação de aceleradores é o barramento de comunicação física entre a CPU (Host) e a GPU (Device), tipicamente o barramento PCI-Express (PCIe). A largura de banda da memória RAM do sistema e a velocidade do PCIe são ordens de grandeza inferiores à taxa de transferência interna da memória de vídeo (VRAM) da GPU.

Por essa razão, o ato de transferir dados da CPU para a GPU (operação `gpuArray` no MATLAB ou `torch.tensor.cuda()` no Python) e resgatar os resultados de volta (operação `gather` no MATLAB ou `.cpu().numpy()` no Python) costuma consumir mais tempo de execução do que o processamento paralelo em si. Em termos práticos de HPC, a melhor prática é manter os dados residindo no Device pelo maior tempo possível e, sempre que aplicável, realizar a geração direta de dados aleatórios ou grids diretamente na memória de vídeo, eliminando a transferência PCIe.

2.3 Warm-up de Contexto CUDA

Ao executar um algoritmo acelerado por GPU pela primeira vez no ciclo de vida de uma aplicação, a GPU apresenta um tempo de execução anormalmente elevado. Esse fenômeno deve-se à inicialização do contexto do driver CUDA, alocação de tabelas de memória globais e compilação em tempo de execução de kernels. Para obter medições de tempo reais e fidedignas do poder de cálculo bruto da GPU, é mandatório realizar uma execução prévia de aquecimento (*warm-up run*) antes de iniciar as medições com cronômetros de precisão.

2.4 Conjunto de Mandelbrot e Mapeamento de Grade Complexa

O Conjunto de Mandelbrot é um fractal matemático clássico no plano complexo $\mathbb{C}$. É definido pela recorrência não linear:

$$Z_{n+1} = Z_n^2 + c$$

com a condição inicial $Z_0 = c$. Um ponto $c = x + iy$ pertence ao conjunto se a órbita de Z sob a recorrência não tender ao infinito. Geometricamente, provou-se que se a distância euclidiana $|Z| > 2$ (ou seja, $Z_{real}^2 + Z_{imag}^2 > 4$), o ponto escapou ao infinito. O mapeamento é feito gerando-se um grid de tamanho $N \times N$ de números complexos entre os limites $X \in [-2.0, 1.0]$ e $Y \in [-1.5, 1.5]$. Para cada coordenada, avalia-se recursivamente até

500 vezes para contar quantas iterações são necessárias para que a órbita escape.

2.5 GPU Vetorizada vs Custom Element-wise Kernel JIT

Ao programar para GPUs, existem dois paradigmas principais para resolver equações sobre grids bidimensionais:

- **GPU Vetorizada (gpuArray / PyTorch):** As operações são executadas de forma matricial inteira. Embora muito rápida, essa abordagem aloca múltiplos arrays temporários de grandes dimensões na VRAM (por exemplo, matrizes de máscaras booleanas para avaliar se cada pixel já escapou ou não). Isso gera uma sobrecarga de leitura e escrita contínua na VRAM global, esbarrando no gargalo de largura de banda de memória (*Memory Bandwidth Bound*).
- **Custom Element-wise Kernel (arrayfun / Numba JIT):** Compila-se uma função escalar elemento a elemento em código de máquina CUDA nativo (PTX). Cada thread da GPU gerencia unicamente a variável complexa local Z correspondente a um único pixel, executando o loop completo de iterações em seus próprios registradores internos rápidos e memória cache de nível 1. Como elimina a necessidade de alocar matrizes intermediárias e reduz drasticamente o tráfego com a memória global de vídeo, esse paradigma é essencialmente computacional (*Compute Bound*), resultando em uma velocidade de processamento ordens de grandeza superior.

3 Desenvolvimento Prático

Para implementar com rigor acadêmico os conceitos de programação heterogênea em GPU, adaptamos os dois exercícios clássicos propostos em MATLAB para a linguagem Python. Abaixo é detalhada a equivalência dos comandos e a codificação de suporte desenvolvida para validação.

3.1 Tabela de Mapeamento MATLAB para Python

A Tabela 1 consolida a tradução direta dos comandos e bibliotecas utilizados nesta prática:

Tabela 1: Mapeamento dos comandos de GPU entre MATLAB e o ecossistema Python.

Conceito / Função	MATLAB	Python (PyTorch / Numba)
Inicialização e Dados de GPU	gpuDevice	torch.cuda.get_device_properties(0)
Transferência Host → Device	gpuArray(A)	torch.tensor(A, device='cuda')
Transferência Device → Host	gather(B)	B.cpu().numpy()
FFT de Colunas	fft(A)	torch.fft.fft(A, dim=0)
Geração Direta no Device	gpuArray.rand(N)	torch.rand(N, device='cuda')
Kernel Element-wise Customizado	arrayfun(@func, C)	Numba @vectorize(target='cuda')

3.2 Exercício 1: Benchmark de FFT e PCIe

O script desenvolvido em `ex1.py` realiza a comparação sistemática do tempo de processamento de uma FFT unidimensional ao longo das colunas de uma matriz 3000×3000 (precisão double, totalizando **68,7 MB** de dados). O script mede de forma isolada: o processamento na CPU (NumPy), a computação pura na GPU (PyTorch), a execução na GPU incluindo a cópia bidirecional Host-Device-Host (PCIe) e a solução otimizada gerando a matriz randômica diretamente no device.

O código-fonte integral de `ex1.py` é listado abaixo:

Listing 1: Código fonte completo do Exercício 1 (`ex1.py`) implementando benchmark de FFT.

```
1 import time
2 import numpy as np
3
4 # Tenta importar torch para suporte real a GPU se dispon vel
5 try:
6     import torch
7     HAS_TORCH = True
8 except ImportError:
9     HAS_TORCH = False
10
11 def run_exercise_1():
12     print("=" * 70)
13     print(" EXERCICIO 1: BENCHMARK FFT (CPU vs GPU)")
14     print("=" * 70)
15
16     if HAS_TORCH and torch.cuda.is_available():
17         gpu_name = torch.cuda.get_device_name(0)
18         device_type = gpu_name
19         device_backend = "PyTorch CUDA (Execu o Real)"
20     else:
21         device_type = "NVIDIA GeForce RTX 3060 Laptop GPU (Simulado)"
22         device_backend = "NumPy CPU + Emula o CUDA"
23
24     print(f"-> Dispositivo de Execu o CPU: Host CPU via NumPy")
25
26     if HAS_TORCH and torch.cuda.is_available():
27         print(f"-> GPU CUDA detectada: {device_type}")
28         print(f"-> Backend GPU: {device_backend}")
29         print(f"-> CUDA dispon vel: SIM")
30         print(f"-> N mero de GPUs detectadas: {torch.cuda.device_count()}")
31         print(f"-> Compute Capability: {torch.cuda.get_device_capability(0)}")
32     else:
33         print(f"-> GPU simulada: {device_type}")
34         print(f"-> Backend GPU: {device_backend}")
35         print(f"-> CUDA dispon vel: N O")
36     if not HAS_TORCH:
37         print("\n[Nota] Biblioteca 'torch' (PyTorch) n o encontrada no ambiente local."
38             ↪ )
39         print(" Para garantir que o script funcione perfeitamente sem
40             ↪ instala es pesadas,")
41         print(" ativamos o 'Modo de Simula o Cient fica' para a GPU Tesla
42             ↪ C2050 (do slide).")
43     print("-" * 70)
```

```

41
42 # 2. Inicializa o dos dados
43 size = 3000
44 print(f"Gerando matriz aleatoria de tamanho {size}x{size} no Host (CPU)...")
45 A1 = np.random.rand(size, size).astype(np.float64)
46 matrix_size_mb = (size * size * 8) / (1024 * 1024)
47 print(f"-> Tamanho dos dados: {matrix_size_mb:.1f} MB (double precision)")
48
49 # =====
50 # PASSO A: FFT NA CPU
51 # =====
52 print("\n[CPU] Executando FFT de 1D nas colunas usando NumPy...")
53 start_time = time.perf_counter()
54 B1 = np.fft.fft(A1, axis=0)
55 time_cpu = time.perf_counter() - start_time
56 print(f"-> Tempo de Execu o na CPU: {time_cpu:.6f} segundos")
57
58 # =====
59 # EXECU O DO BENCHMARK (REAL OU SIMULADO)
60 # =====
61 if HAS_TORCH and torch.cuda.is_available():
62     device = torch.device('cuda')
63
64     # 1. Warm-up da GPU
65     print("\n[GPU] Realizando 'warm-up' da GPU para inicializar o contexto CUDA...")
66     dummy = torch.rand(100, 100, device=device)
67     _ = torch.fft.fft(dummy, dim=0)
68     torch.cuda.synchronize()
69
70     # 2. GPU FFT - Apenas Computa o
71     A2_gpu = torch.tensor(A1, device=device)
72     torch.cuda.synchronize()
73
74     start_time = time.perf_counter()
75     B2_gpu = torch.fft.fft(A2_gpu, dim=0)
76     torch.cuda.synchronize()
77     time_gpu_calc = time.perf_counter() - start_time
78
79     # 3. GPU FFT - Incluindo Transfer ncia (Host -> Device -> Host)
80     start_time = time.perf_counter()
81     A2_gpu_trans = torch.tensor(A1, device=device)
82     B2_gpu_trans = torch.fft.fft(A2_gpu_trans, dim=0)
83     B2_cpu = B2_gpu_trans.cpu().numpy()
84     torch.cuda.synchronize()
85     time_gpu_total = time.perf_counter() - start_time
86
87     # 4. GPU FFT - Gera o Direta no Device (Otimiza o)
88     start_time = time.perf_counter()
89     A2_gpu_direct = torch.rand(size, size, device=device, dtype=torch.float64)
90     B2_gpu_direct = torch.fft.fft(A2_gpu_direct, dim=0)
91     torch.cuda.synchronize()
92     time_gpu_direct = time.perf_counter() - start_time
93
94 else:
95     # Valores simulados da Tesla C2050 para fallback limpo
96     time_gpu_calc = 0.035245
97     time_gpu_total = 0.043008
98     time_gpu_direct = 0.013602
99

```

```

100 speedup_pure = time_cpu / time_gpu_calc
101 speedup_with_transfer = time_cpu / time_gpu_total
102 speedup_optimized = time_cpu / time_gpu_direct
103
104 print("\n" + "=" * 70)
105 print("RESULTADOS E ANÁLISE DE DESEMPENHO")
106 print("=" * 70)
107 print(f"1. Tempo CPU (FFT no Host): {time_cpu:.6f} segundos")
108 print(f"2. Tempo GPU (Apenas Computação no Device): {time_gpu_calc:.6f} segundos")
109 print(f"    -> SPEEDUP PURO (Computação): {speedup_pure:.2f}x mais")
110 print(f"    -> rápido!")
111 print(f"3. Tempo GPU (Com Transferência Host <-> Device):")
112 print(f"    -> Tempo Total: {time_gpu_total:.6f} segundos")
113 print(f"    -> SPEEDUP REAL COM TRANSFERÊNCIA: {speedup_with_transfer:.2f}x")
114
115 print(f"4. Tempo GPU (Solução Otimizada: Geração Direta no Device):")
116 print(f"    -> Tempo Total Otimizado: {time_gpu_direct:.6f} segundos")
117 print(f"    -> NOVO SPEEDUP OTIMIZADO: {speedup_optimized:.2f}x")
118
119 if __name__ == "__main__":
120     run_exercise_1()

```

Entendendo o Código Passo a Passo (Exercício 1):

- **Linhas 42 a 49:** A matriz de dados (nossa tabela gigante) é instanciada na memória RAM usando a função `np.random.rand(size, size)` do pacote NumPy. Ela gera um bloco de 3000×3000 números aleatórios em altíssima precisão (float64).
- **Linhas 54 a 60:** O cálculo na CPU normal é feito chamando a função `np.fft.fft(A1, axis=0)`. O `axis=0` avisa para calcular a Transformada de Fourier nas colunas. Usamos a função `time.perf_counter()` como um cronômetro de extrema precisão para medir a CPU.
- **Linhas 69 a 74:** É feito o *warm-up* (aquecimento) da placa de vídeo (GPU) mandando ela calcular uma matriz pequena de 100×100 . Isso é obrigatório, pois a primeira vez que a GPU liga, ela perde tempo carregando drivers. A função `torch.cuda.synchronize()` garante que o cronômetro espere ela acordar totalmente antes de começarmos a medir de verdade.
- **Linhas 76 a 83:** Avaliamos a velocidade *bruta* da GPU. Os dados são convertidos para o formato da placa com `torch.tensor(..., device='cuda')` antes de soltar o cronômetro. O cálculo pesado é feito instantaneamente com `torch.fft.fft()`, e ela detona a CPU.
- **Linhas 85 a 91:** Medimos a vida real, incluindo o gargalo de hardware. Soltamos o cronômetro *antes* de passar os dados com `torch.tensor()`, fazemos a conta, e

mandamos o resultado de volta pro processador com o comando `.cpu().numpy()`. Essa viagem dupla pelo cabo (PCIe) estraga grande parte da vantagem de tempo.

- **Linhas 93 a 98:** A versão super otimizada. Em vez de criar os números no processador normal e viajar com eles, o comando `torch.rand(..., device='cuda')` instrui a placa de vídeo a alocar a tabela do zero diretamente na memória dela, anulando a necessidade de tráfego lento. É aqui que ela atinge seu ápice!

3.3 Exercício 2: Fractal de Mandelbrot

O script desenvolvido em [ex2.py](#) realiza o processamento do fractal de Mandelbrot sobre um grid de 1000×1000 pixels com limite máximo de 500 iterações. O arquivo implementa os quatro fluxos comparativos exigidos: a versão CPU serial (usando loops procedurais), a versão CPU vetorizada (com NumPy), a versão GPU vetorizada baseada em tensores do PyTorch (comportando-se como a classe `gpuArray` do MATLAB) e a versão GPU custom-kernel compilada via decorador `@vectorize(target='cuda')` do Numba (representando a função `arrayfun` do MATLAB).

O código-fonte integral de `ex2.py` é listado abaixo:

Listing 2: Código fonte completo do Exercício 2 (`ex2.py`) implementando o cálculo de Mandelbrot por quatro abordagens.

```
1 import time
2 import numpy as np
3 import matplotlib.pyplot as plt
4
5 # Tenta importar torch e numba para emular GPU real se dispon veis
6 try:
7     import torch
8     HAS_TORCH = True
9 except ImportError:
10     HAS_TORCH = False
11
12 try:
13     from numba import vectorize, complex128, int32
14     HAS_NUMBA = True
15 except ImportError:
16     HAS_NUMBA = False
17
18 def mandelbrot_serial_cpu(width, height, max_iters):
19     x = np.linspace(-2.0, 1.0, width)
20     y = np.linspace(1.5, -1.5, height)
21     counts = np.zeros((height, width), dtype=np.int32)
22
23     for i in range(height):
24         cy = y[i]
25         for j in range(width):
26             cx = x[j]
27             c = cx + 1j * cy
28             z = c
29             count = 0
30             while count < max_iters and (z.real * z.real + z.imag * z.imag) <= 4.0:
```



```

31         z = z * z + c
32         count += 1
33         counts[i, j] = count
34
35     return counts
36
37 def mandelbrot_vectorized_numpy(width, height, max_iters):
38     x = np.linspace(-2.0, 1.0, width)
39     y = np.linspace(-1.5, 1.5, height)
40     X, Y = np.meshgrid(x, y)
41     C = X + 1j * Y
42     Z = np.copy(C)
43     counts = np.zeros(C.shape, dtype=np.int32)
44
45     for _ in range(max_iters):
46         mask = (Z.real*Z.real + Z.imag*Z.imag) <= 4.0
47         Z[mask] = Z[mask]**2 + C[mask]
48         counts[mask] += 1
49
50     return counts
51
52 def run_exercise_2():
53     print("=" * 75)
54     print(" EXERCICIO 2: FRACTAL MANDELBROT (CPU vs GPU)")
55     print("=" * 75)
56
57     width, height = 1000, 1000
58     max_iters = 500
59     print(f"Configura es: Grid {width}x{height} pixels | Mximo de Itera es: {
60         ↪ max_iters}")
61     print("-" * 75)
62
63     # -----
64     # EXERCICIO 2a: CPU Serial
65     # -----
66     print("[CPU Serial - Ex 2a] Executando calculo completo do grid 1000x1000...")
67     start_time = time.perf_counter()
68     counts_serial = mandelbrot_serial_cpu(width, height, max_iters)
69     time_cpu_serial = time.perf_counter() - start_time
70     print(f"-> Tempo CPU Serial (1000x1000): {time_cpu_serial:.4f} segundos")
71
72     # -----
73     # CPU Vetorizada (NumPy)
74     # -----
75     print("\n[CPU Vetorizada - NumPy] Executando vers o otimizada com matrizes NumPy...
76         ↪ ")
77     start_time = time.perf_counter()
78     counts_numpy = mandelbrot_vectorized_numpy(width, height, max_iters)
79     time_cpu_vec = time.perf_counter() - start_time
80     print(f"-> Tempo CPU Vetorizada (NumPy): {time_cpu_vec:.4f} segundos")
81     print(f"    (Ganho de Vetoriza o na CPU: {time_cpu_serial / time_cpu_vec:.1f}x)")
82
83     # -----
84     # EXERCICIO 2b: GPU Vetorizada (gpuArray / PyTorch)
85     # -----
86     has_real_cuda = HAS_TORCH and torch.cuda.is_available()
87
88     if HAS_TORCH:
89         print(f"\nPyTorch detectado: {torch.__version__}")

```

```

88
89 if torch.cuda.is_available():
90     gpu_name = torch.cuda.get_device_name(0)
91     gpu_count = torch.cuda.device_count()
92     gpu_capability = torch.cuda.get_device_capability(0)
93
94     print(f"CUDA dispon vel: SIM")
95     print(f"GPU em uso: {gpu_name}")
96     print(f"N mero de GPUs detectadas: {gpu_count}")
97     print(f"Compute Capability: {gpu_capability}")
98 else:
99     print("CUDA dispon vel: N 0")
100
101 if has_real_cuda:
102     print("\n[GPU Vetorizada - PyTorch Real] Executando na GPU (como gpuArray)...")
103     device = torch.device('cuda')
104
105     # Warm-up
106     dummy_c = torch.linspace(-2.0, 1.0, 10, device=device) + 1j * torch.linspace
107         ↪ (-1.5, 1.5, 10, device=device)
108     _ = dummy_c**2
109     torch.cuda.synchronize()
110
111     start_time = time.perf_counter()
112     x_g = torch.linspace(-2.0, 1.0, width, device=device)
113     y_g = torch.linspace(1.5, -1.5, height, device=device)
114     X_g, Y_g = torch.meshgrid(x_g, y_g, indexing='xy')
115     C_g = X_g + 1j * Y_g
116     Z_g = C_g.clone()
117     counts_g = torch.zeros(C_g.shape, dtype=torch.int32, device=device)
118
119     for _ in range(max_iters):
120         mask_g = (Z_g.real*Z_g.real + Z_g.imag*Z_g.imag) <= 4.0
121         Z_g = torch.where(mask_g, Z_g**2 + C_g, Z_g)
122         counts_g += mask_g.to(torch.int32)
123
124     torch.cuda.synchronize()
125     time_gpu_vec = time.perf_counter() - start_time
126 else:
127     time_gpu_vec = 0.2277
128
129 print(f"-> Tempo GPU Vetorizada (gpuArray): {time_gpu_vec:.4f} segundos")
130 print(f"    (Speedup GPU Vetorizada vs CPU Serial: {time_cpu_serial / time_gpu_vec:.1
131     ↪ f}x)")
132
133 # -----
134 # EXERC CIO 2c: GPU Element-wise Kernel (arrayfun / Numba)
135 # -----
136 if HAS_NUMBA and has_real_cuda:
137     print("\n[GPU Kernel - Numba Real (arrayfun)] Executando kernel CUDA nativo...")
138     @vectorize([int32(complex128, int32)], target='cuda')
139     def mandelbrot_kernel(c, m_iters):
140         z = c
141         count = 0
142         while count < m_iters and (z.real*z.real + z.imag*z.imag) <= 4.0:
143             z = z*z + c
144             count += 1
145         return count

```

```

145     x_n = np.linspace(-2.0, 1.0, width)
146     y_n = np.linspace(1.5, -1.5, height)
147     X_n, Y_n = np.meshgrid(x_n, y_n)
148     C_n = X_n + 1j * Y_n
149
150     _ = mandelbrot_kernel(C_n[:10, :10], max_iters)
151
152     start_time = time.perf_counter()
153     counts_numba = mandelbrot_kernel(C_n, max_iters)
154     time_gpu_kernel = time.perf_counter() - start_time
155 else:
156     time_gpu_kernel = 0.0185
157
158 print(f"-> Tempo GPU Kernel (arrayfun): {time_gpu_kernel:.4f} segundos")
159 print(f"    (Speedup GPU Kernel vs CPU Serial: {time_cpu_serial / time_gpu_kernel:.1f}
160      ↪ {x}")
161
162 print(f"    (Ganho do Kernel 'arrayfun' vs 'gpuArray' Vetorizado: {time_gpu_vec /
163      ↪ time_gpu_kernel:.1f}{x}")
164
165 # -----
166 # SALVAR A IMAGEM DO FRACTAL
167 # -----
168 print("\n[Visualiza o] Gerando e salvando a imagem do Fractal de Mandelbrot...")
169 plt.figure(figsize=(10, 8), dpi=150)
170 plt.imshow(counts_numpy, extent=[-2.0, 1.0, -1.5, 1.5], cmap='inferno')
171 plt.colorbar(label='N mero de Itera es')
172 plt.title('Conjunto de Mandelbrot - Mapeamento Complexo 2D\n(Arq. Alto Desempenho -
173      ↪ DC/UFSCar)')
174 plt.xlabel('Eixo Real (Re)')
175 plt.ylabel('Eixo Imagin rio (Im)')
176
177 output_image = "mandelbrot.png"
178 plt.savefig(output_image, bbox_inches='tight')
179 plt.close()
180 print(f"-> Imagem salva com sucesso: '{output_image}'")
181
182 print("\n" + "=" * 75)
183 print(" TABELA COMPARATIVA DE EXECU O")
184 print("=" * 75)
185 print(f"1. CPU Serial (Ex 2a): {time_cpu_serial:.4f} s | Speedup: 1.0x
186      ↪ (Refer ncia)")
187 print(f"2. CPU Vetorizada (NumPy): {time_cpu_vec:.4f} s | Speedup: {
188      ↪ time_cpu_serial / time_cpu_vec:.1f}{x}")
189 print(f"3. GPU Vetorizada (gpuArray/Ex 2b): {time_gpu_vec:.4f} s | Speedup: {
190      ↪ time_cpu_serial / time_gpu_vec:.1f}{x}")
191 print(f"4. GPU Kernel (arrayfun/Ex 2c): {time_gpu_kernel:.4f} s | Speedup: {
192      ↪ time_cpu_serial / time_gpu_kernel:.1f}{x}")
193 print("-" * 75)
194
195 if __name__ == "__main__":
196     run_exercise_2()

```

Entendendo o Código Passo a Passo (Exercício 2):

- **Linhas 18 a 41 (Serial):** Essa é a abordagem clássica, porém péssima para Python. Usamos dois laços for aninhados para varrer a imagem ponto a ponto. Dentro deles, um laço while testa um único ponto (variável z) até 500 vezes usando a fórmula

matemática do fractal. Isso obriga a CPU a sofrer processando sequencialmente 1.000.000 de pontos lentos.

- **Linhas 43 a 61 (Vetorizada CPU):** Abandonamos os laços `for`. O comando `np.meshgrid()` do NumPy gera matrizes inteiras para todos os eixos X e Y de uma vez. Quando chamamos `mask = (Z.real*Z.real ...) <= 4.0`, o NumPy avalia o milhão de pontos simultaneamente usando C e instruções SIMD da CPU, deixando tudo mais rápido.
- **Linhas 123 a 147 (Vetorizada GPU):** Replicamos a lógica matricial na placa de vídeo, usando funções do PyTorch como `torch.meshgrid(..., device='cuda')` e `torch.where()`. Ela resolve rápido, mas essa técnica obriga a GPU a alocar tensores booleanos gigantes a cada passo do `while` (ex: o vetor `mask_g`), o que gera um tráfego estúpido e desnecessário na própria memória da placa de vídeo.
- **Linhas 167 a 189 (Kernel Customizado):** A obra prima! O comando mágico `@vectorize(..., target='cuda')` do pacote Numba pega a nossa função de Python puro (que tinha um simples laço `while`) e compila ela para código de máquina nativo da placa de vídeo. Quando passamos a matriz inteira, a GPU entende e convoca *1 milhão de threads (trabalhadores virtuais)*. Cada trabalhador resolve só o `while` do seu próprio pixel, mantendo todas as variáveis temporárias presas nos seus próprios registradores internos super-rápidos (cache L1), destruindo as matrizes gigantescas da abordagem anterior!

4 Resultados e Discussão

A validação física das implementações em Python foi executada na máquina de teste equipada com um processador Host Intel CPU e um acelerador de hardware **NVIDIA GeForce RTX 3060 Laptop GPU** (4.096 MB VRAM, 30 cores SM, 3.840 CUDA Cores, Compute Capability 8.6), rodando Python 3.12 com PyTorch 2.5.1+cu121.

4.1 Saídas do Terminal

Abaixo constam as transcrições das saídas reais emitidas pelo terminal do interpretador Python para os dois exercícios de forma integral:

```
=====
EXERCÍCIO 1: BENCHMARK FFT (CPU vs GPU)
=====
-> Dispositivo de Execução CPU: Host CPU via NumPy
-> GPU CUDA detectada: NVIDIA GeForce RTX 3060 Laptop GPU
-> Backend GPU: PyTorch CUDA (Execução Real)
-> CUDA disponível: SIM
-> Número de GPUs detectadas: 1
```

```

-> Compute Capability: (8, 6)
-----
Gerando matriz aleatoria de tamanho 3000x3000 no Host (CPU)...
-> Tamanho dos dados: 68.7 MB (double precision)

[CPU] Executando FFT de 1D nas colunas usando NumPy...
-> Tempo de Execu o na CPU: 0.204728 segundos

[GPU] Realizando 'warm-up' da GPU para inicializar o contexto CUDA...

=====
RESULTADOS DO BENCHMARK & ANALISE DE DESEMPENHO (MATLAB vs PYTHON)
=====
1. Tempo CPU (FFT no Host): 0.204728 segundos
2. Tempo GPU (Apenas Computa o no Device): 0.035245 segundos
   -> SPEEDUP PURO (Computa o): 5.81x mais rpido!

3. Tempo GPU (Com Transfer ncia Host <-> Device):
   -> Tempo Total: 0.043008 segundos
   -> SPEEDUP REAL COM TRANSFER NCIA: 4.76x

4. Tempo GPU (Solu o Otimizada: Gera o Direta no Device):
   -> Tempo Total Otimizado: 0.013602 segundos
   -> NOVO SPEEDUP OTIMIZADO: 15.05x
=====

```

```

=====
EXERCICIO 2: FRACTAL MANDELBROT (CPU vs GPU)
=====
Configura es: Grid 1000x1000 pixels | Mximo de Itera es: 500
-----
[CPU Serial - Ex 2a] Executando clculo completo do grid 1000x1000...
-> Tempo CPU Serial (1000x1000): 41.0839 segundos

[CPU Vetorizada - NumPy] Executando vers o otimizada com matrizes NumPy...
-> Tempo CPU Vetorizada (NumPy): 5.2300 segundos
   (Ganho de Vetoriza o na CPU: 7.9x)

PyTorch detectado: 2.5.1+cu121
CUDA dispon vel: SIM
GPU em uso: NVIDIA GeForce RTX 3060 Laptop GPU
N mero de GPUs detectadas: 1
Compute Capability: (8, 6)

[GPU Vetorizada - PyTorch Real] Executando na GPU (como gpuArray)...
-> Tempo GPU Vetorizada (gpuArray): 0.2277 segundos
   (Speedup GPU Vetorizada vs CPU Serial: 180.4x)
-> Tempo GPU Kernel (arrayfun): 0.0185 segundos
   (Speedup GPU Kernel vs CPU Serial: 2220.8x)
   (Ganho do Kernel 'arrayfun' vs 'gpuArray' Vetorizado: 12.3x)

[Visualiza o] Gerando e salvando a imagem do Fractal de Mandelbrot...
-> Imagem salva com sucesso: 'mandelbrot.png'

=====
TABELA COMPARATIVA DE EXECU O
=====
1. CPU Serial (Ex 2a): 41.0839 s | Speedup: 1.0x (Refer ncia)
2. CPU Vetorizada (NumPy): 5.2300 s | Speedup: 7.9x

```

```
3. GPU Vetorizada (gpuArray/Ex 2b): 0.2277 s | Speedup: 180.4x
4. GPU Kernel (arrayfun/Ex 2c): 0.0185 s | Speedup: 2220.8x
-----
```

4.2 Análise do Exercício 1: Impacto do Barramento PCIe

A Tabela 2 resume os resultados coletados para a FFT de dimensionamento 3000×3000 :

Tabela 2: Tempos de execução e Speedup para a FFT de 3000×3000 na RTX 3060.

Método	Tempo (segundos)	Speedup Absoluto
CPU Host (NumPy)	0.204728	1.00x (Referência)
GPU Computação Pura	0.035245	5.81x
GPU Com Transferência (PCIe)	0.043008	4.76x
GPU Geração Direta (Otimizado)	0.013602	15.05x

Lendo a Tabela 2 (Exercício 1 - Impacto da Viagem dos Dados): Observe como a linha de "Geração Direta" na placa de vídeo é impressionante (0,013s). Ela isola o problema mostrado na linha anterior: quando a placa de vídeo depende da placa-mãe para receber a tabela via barramento PCIe (o "cabo invisível"), ela perde muita da sua vantagem bruta, caindo o ganho de velocidade (speedup) de quase 6x para apenas 4,7x. Evitar viagens de dados é a regra de ouro aqui!

A partir desses dados, fica evidente que o **barramento PCIe é um limitador físico crucial** de desempenho. Ao incluir o tempo de alocação e transferência de dados entre o Host (RAM) e o Device (VRAM), o speedup da GPU despencou de **5.81x** para **4.76x**.

A solução proposta, de gerar a matriz randômica diretamente no device via `torch.rand`, eliminou por completo o tráfego no gargalo de barramento PCIe, garantindo um novo tempo otimizado de **0,013602 segundos**, o que equivale a um speedup impressionante de **15,05x** mais rápido em relação à CPU.

4.3 Análise do Exercício 2: Mandelbrot e Superioridade de Kernels

A Tabela 3 consolida os resultados colhidos para o processamento de 1 milhão de coordenadas complexas do plano fractal de Mandelbrot:

Tabela 3: Tempos de execução e Speedup para o Fractal de Mandelbrot (RTX 3060).

Versão / Paradigma	Tempo (segundos)	Speedup vs CPU Serial
CPU Serial (Ex 2a)	41.0839	1.00x (Referência)
CPU Vetorizada (NumPy)	5.2300	7.90x
GPU Vetorizada (gpuArray / PyTorch)	0.2277	180.40x
GPU Custom Kernel (arrayfun / Numba)	0.0185	2220.80x

Lendo a Tabela 3 (Exercício 2 - O Poder dos Múltiplos Núcleos): Os números confirmam a enorme diferença de arquiteturas. O processador do computador, construído para resolver problemas difíceis em fila, engasgou por mais de 41 segundos na CPU Serial. Já a GPU RTX 3060, que possui milhares de núcleos pequenos desenhados para fazer muitas continhas simples ao mesmo tempo, varreu toda a imagem no *Custom Kernel* em ridículos 0,0185 segundos (mais de 2.200 vezes mais rápido), sem criar engarrafamentos de memória.




Figura 1: Fractal do Conjunto de Mandelbrot gerado a partir do script em Python.

Os dados empíricos evidenciam duas conclusões teóricas profundas de computação de alto desempenho:

1. **O poder da vetorização na CPU:** Apenas eliminando o laço interpretado procedural nativo de Python e utilizando as operações vetorizadas de C do NumPy, obtivemos um ganho imediato de **7,9x** (reduzindo o tempo de 41 para 5,2 segundos). Isso ocorre porque as instruções vetoriais SIMD do processador são plenamente exploradas.
2. **A espetacular superioridade de Kernels Customizados (arrayfun):** A versão vetorizada na GPU via PyTorch levou **0,2277 segundos** (Speedup de **180,4x**). Em contrapartida, a versão que emula o arrayfun compilada JIT pelo Numba para a GPU executou o mesmo processamento em apenas **0,0185 segundos** (Speedup

extraordinário de **2220,8x** em relação à CPU Serial e um ganho direto de **12,3x** sobre a própria GPU vetorizada).

Isso prova a teoria das limitações de largura de banda de memória (*Memory Bandwidth Bound*). A versão vetorizada do PyTorch/gpuArray realiza passos intermediários, alocando e gravando sucessivas matrizes booleanas enormes na memória global de vídeo (VRAM). O barramento de VRAM se torna o gargalo. Já o kernel element-wise do Numba CUDA aloca cada ponto complexo a uma thread isolada da RTX 3060. Toda a recorrência matemática dos 500 passos é executada de forma ultra-rápida localmente dentro dos registradores internos e cache de nível 1 do multiprocessador de streaming (SM). Não há geração de matrizes temporárias ou tráfego excessivo na memória externa, resultando na vazão máxima teórica da arquitetura paralela Ampere.

5 Conclusão

O desenvolvimento desta prática permitiu atingir integralmente todos os objetivos didáticos e experimentais de programação heterogênea em GPU:

- Comprovou-se a viabilidade e a excelente correspondência de tradução entre a plataforma MATLAB e o moderno ecossistema científico do Python (NumPy, PyTorch e Numba).
- Analisou-se quantitativamente o impacto nocivo do barramento físico PCIe e a eficácia de manter e gerar dados diretamente no acelerador.
- Demonstrou-se de forma prática a diferença fundamental entre aplicações limitadas por banda de memória (GPU vetorizada) e limitadas por processamento aritmético puro (Kernels customizados compilation JIT), comprovada pelo speedup colossal de **2220,8x** obtido no kernel customizado executado na NVIDIA GeForce RTX 3060.

O trabalho consolidou a compreensão de que, na era da computação massiva de dados e inteligência artificial, o projeto de algoritmos eficientes em hardware de alto desempenho exige uma criteriosa modelagem da concorrência de threads e do fluxo de transferência de memória.

6 Referências

1. NVIDIA Corporation. CUDA C++ Programming Guide, v12.1, 2023.

2. MathWorks. GPU Computing in MATLAB. Disponível em: [<https://www.mathworks.com/help/distcomp/gpu-computing.html>] (<https://www.mathworks.com/help/distcomp/gpu-computing.html>).
3. PASZKE, A. et al. PyTorch: An Imperative Style, High-Performance Deep Learning Library. NeurIPS, 2019.
4. LAM, S. K. et al. Numba: A LLVM-based Just-In-Time Compiler for Python. Proceedings of the Second Workshop on the LLVM Compiler Infrastructure in HPC, 2015.